

Automatización y análisis de datos climatológicos.

Por: Sergio Bouchán Catalán



Índice

Objetivo	3
Descripción de la API.....	3
Descripción de los datos	3
Flujo de trabajo	4
Extracción de datos.....	4
Transformación de datos	5
Almacenamiento de datos (Load).....	5
Automatización.....	6
Aplicación Web	7
Resultados.....	7
Conclusiones.....	8

Objetivo

Diseñar e implementar un pipeline ETL automatizado para la recopilación y análisis de datos meteorológicos de distintas ciudades de México. Se pretende que el sistema extraiga información desde la API de Open-Meteo, realice procesos de transformación y validación con Python, almacene un histórico de registros en una base de datos y permite su consulta mediante un dashboard interactivo desarrollado en Streamlit, dentro de una arquitectura en la nube que permita la ejecución programada del pipeline y el acceso remoto a los datos.

Descripción de la API

Open-Meteo es una API meteorológica que permite consultar información climática mediante solicitudes HTTP a partir de coordenadas geográficas. La API proporciona datos como temperatura, humedad relativa, precipitación y velocidad del viento, entre otras variables meteorológicas; la información es devuelta en formato JSON, lo que facilita su consumo y procesamiento mediante lenguajes como Python que es el empleado en este proyecto. En este caso se utilizó el endpoint de pronóstico de Open-Meteo para obtener las condiciones meteorológicas actuales de diferentes ciudades de México y desarrollar el pipeline ETL automatizado.

Descripción de los datos

En la tabla 1 se muestran las variables de la API que fueron ocupadas para este proyecto.

Tabla 1: Descripción de variables.

Variable	Tipo de variable	Descripción
ciudad	Texto	Ciudad de la que se obtienen los datos.
fecha_hora	Texto	Fecha y hora de la obtención de los datos.
temperatura	Numérica	Temperatura en grados Celsius de la ciudad.
humedad	Numérica	Porcentaje de humedad en la ciudad.
precipitación	Numérica	Milímetros de agua en cualquier estado que caen desde la atmósfera.
velocidad_viento	Numérica	Velocidad del viento en kilómetros por hora.

Flujo de trabajo

El sistema fue diseñado para recopilar automáticamente información meteorológica de diferentes ciudades de México y construir un histórico de datos que pueda consultarse posteriormente.

En cada ejecución, el proceso obtiene las condiciones del clima más recientes de las ciudades seleccionadas, organiza y valida la información y la incorpora al histórico únicamente cuando se trata de una nueva observación (las nuevas observaciones ocurren cada 15 minutos). Este proceso se ejecuta de forma programada, reduciendo la necesidad de intervención manual y permitiendo que la base de datos crezca progresivamente con nuevas observaciones sin necesidad de que los registros se agreguen manualmente.

Finalmente, la información recopilada puede consultarse mediante un dashboard interactivo, donde el usuario puede seleccionar una ciudad, analizar su comportamiento durante un periodo determinado y comparar las condiciones meteorológicas entre diferentes ubicaciones. En la figura 1 se observa este flujo de trabajo en un diagrama.




Figura 1: Flujo de trabajo del proyecto.

Extracción de datos

La primera etapa del proyecto consiste en la recopilación automática de información meteorológica desde la API de Open-Meteo. Para ello, el sistema consulta periódicamente las condiciones meteorológicas de las ciudades seleccionadas y obtiene una nueva observación para cada una de ellas.

Las ciudades incluidas actualmente son Ciudad de México, Monterrey, Guadalajara, Cancún y Puebla. Cada ubicación se encuentra asociada a sus coordenadas geográficas, lo que permite solicitar a la API la información correspondiente a cada ciudad y en cada consulta se recopilan las variables utilizadas de temperatura, humedad relativa, precipitación y velocidad del viento, además de la fecha y hora asociadas a la observación.

La extracción fue diseñada para procesar todas las ciudades de manera automática dentro de una misma ejecución. De esta forma, no es necesario realizar consultas manuales para cada ubicación y el conjunto de datos puede actualizarse periódicamente mediante el pipeline. En caso de que alguna consulta no pueda completarse, el sistema identifica el problema y evita incorporar registros inválidos o repetidos, permitiendo que el proceso continúe con las ciudades cuya información sí se encuentra disponible. En la figura 2 se muestra el flujo de la extracción.

Una vez recopiladas las observaciones, los datos pasan a la etapa de transformación.




Figura 2: Flujo de Extracción.

Transformación de datos

Una vez obtenidas las observaciones meteorológicas, la información pasa por una etapa de transformación y validación antes de ser almacenada. En esta fase, los registros obtenidos de las distintas ciudades se organizan en una estructura tabular que facilita su análisis y almacenamiento, además, se verifica que la información contenga todas las variables necesarias para el proyecto, como ciudad, fecha y hora, temperatura, humedad, precipitación y velocidad del viento.

Posteriormente se estandariza el campo de fecha y hora para que pueda utilizarse correctamente en análisis históricos, filtros por periodo y visualizaciones temporales dentro del dashboard.

Si durante esta etapa se detecta que no existen registros disponibles o que falta alguna variable necesaria, el proceso se detiene para evitar que datos incompletos o incorrectos sean incorporados al histórico; de esta forma, la transformación funciona como un control de calidad previo al almacenamiento, asegurando que solo la información válida continúe hacia la siguiente etapa del pipeline.

Una vez validados y organizados, los registros pasan a la etapa de almacenamiento.

Almacenamiento de datos (Load)

Una vez que los datos han sido transformados y validados, las observaciones meteorológicas se almacenan en una base de datos PostgreSQL en la nube de Neon con el propósito de construir un histórico que pueda crecer progresivamente con cada ejecución del pipeline. Cada registro conserva la ciudad, la fecha y hora de la observación, así como los valores de temperatura, humedad, precipitación y velocidad del viento. Esta estructura permite consultar posteriormente la evolución de las condiciones meteorológicas por ubicación y periodo.

Para mantener la calidad del histórico, el sistema incorpora un mecanismo de control de duplicados, una observación se considera única a partir de la combinación entre la ciudad y la fecha y hora del registro, de esta manera, si el pipeline vuelve a recibir una observación que ya se encuentra almacenada, esta no se incorpora nuevamente a la base de datos. Evitar estas repeticiones permite mantener un histórico consistente y facilita los análisis posteriores.

El almacenamiento en la nube, permite que la información pueda ser consultada de forma remota e independiente del equipo local. En la figura 3 se muestra el flujo de almacenamiento




Figura 3: Flujo de Almacenamiento.

Estas tres etapas (extracción, transformación y almacenamiento) son ejecutadas mediante un Pipeline encargado de coordinar el flujo completo de información meteorológica. En cada ejecución, el pipeline obtiene nuevas observaciones desde Open-Meteo, valida y organiza los datos y, finalmente, incorpora únicamente los registros nuevos a la base de datos. Esta integración permite que el proceso funcione de forma continua y estructurada, reduciendo tareas manuales y facilitando la actualización periódica del histórico meteorológico.

El pipeline constituye el núcleo del proyecto, ya que conecta todas las etapas del procesamiento y permite que posteriormente puedan ejecutarse de forma automatizada.

Automatización

Una vez construido el Pipeline y configurado la base PostgreSQL en la nube, la ejecución del pipeline se automatizó mediante GitHub Actions donde el workflow ejecuta automáticamente el proceso ETL cada dos horas, permitiendo recopilar nuevas observaciones meteorológicas sin depender de que el equipo local permanezca encendido. Las credenciales de conexión a la base de datos se administran mediante secretos del repositorio, evitando almacenar información sensible directamente en el código. En la figura 4 se muestra una captura de pantalla de la ejecución exitosa del Pipeline automatizado en la nube.




Figura 4: Ejecución automatizada exitosamente.

Aplicación Web

Se desarrolló una aplicación interactiva en Streamlit para consultar y analizar el histórico meteorológico almacenado en PostgreSQL. La aplicación permite seleccionar una ciudad, definir un periodo de análisis y visualizar indicadores como temperatura, humedad, precipitación y velocidad del viento.

Además, incluye gráficas temporales para analizar la evolución de las variables meteorológicas y una sección de comparación entre ciudades, facilitando la identificación de diferencias en las condiciones climáticas entre distintas ubicaciones.

El dashboard fue subido a la nube de Streamlit Community y consulta directamente la base de datos en la nube de Neon, por lo que puede reflejar los nuevos registros incorporados automáticamente por el pipeline sin necesidad de actualizar archivos locales. En la figura 5 se muestra la aplicación subida y funcionando.




Figura 5: Aplicación.

Resultados

Como resultado del proyecto se obtuvo una solución capaz de recopilar, procesar, almacenar y visualizar información meteorológica de manera automatizada, logrando que el sistema construya progresivamente un histórico de observaciones para distintas ciudades de México, incorporando nuevos registros mediante ejecuciones programadas y evitando duplicados durante el almacenamiento.

A través del dashboard, el usuario puede consultar las condiciones meteorológicas registradas, analizar su evolución a lo largo del tiempo y comparar diferentes ciudades mediante indicadores y visualizaciones interactivas.

A continuación, se enlistan las funcionalidades principales del proyecto:

- Recopilación automática de datos meteorológicos.
- Construcción progresiva de un histórico.
- Validación de datos antes del almacenamiento.
- Prevención de registros duplicados.
- Ejecución programada mediante GitHub Actions.
- Almacenamiento persistente en PostgreSQL.
- Filtros por ciudad y periodo.
- Análisis de temperatura, humedad, precipitación y velocidad del viento.
- Comparación entre diferentes ciudades.
- Dashboard accesible desde la web.

Conclusiones

El desarrollo de este proyecto permitió implementar un flujo completo de datos, desde su extracción mediante una API externa hasta su almacenamiento, automatización y visualización en una aplicación web. El uso de PostgreSQL en Neon, GitHub Actions y Streamlit Community Cloud permitió que la solución sea un sistema independiente de un equipo local que es capaz de actualizarse automáticamente.

Además de facilitar el análisis de información meteorológica, el proyecto permitió integrar diferentes herramientas y conceptos relacionados con ingeniería y análisis de datos, incluyendo consumo de APIs, procesos ETL, validación de información, bases de datos SQL, automatización de procesos, manejo seguro de credenciales y desarrollo de dashboards interactivos.

La arquitectura implementada también permite futuras ampliaciones, como incorporar nuevas ciudades y variables meteorológicas, aumentar la frecuencia de recopilación, desarrollar indicadores adicionales o utilizar el histórico generado para realizar análisis estadísticos y modelos predictivos.